Day 5-1 資料清理數據前處理

如何新建一個 dataframe？

游為翔 / 杜靖愷
出題教練

知識地圖 機器學習前處理 讀取各式資料

CUPOY

機器學習概論 Introduction of Machine Learning

監督式學習
Supervised Learning

前處理 Processing → 探索式數據分析 Exploratory Data Analysis → 特徵工程 Feature Engineering → 模型選擇 Model selection → 參數調整 Fine-tuning → 集成 Ensemble

非監督式學習
Unsupervised Learning

- 分群 Clustering
- 降維 Dimension Reduction

前處理 Processing

資料讀取 → 格式調整 → 填補缺值 → 去離群值 → 特徵縮放

本日知識點目標

了解如何快速驗證 dataframe 操作的程式碼

為什麼新建一個 dataframe 重要？

需要把分析過程中所產生的數據或者結果儲存為結構化的資料

- Ex 1: 將每筆交易資料匯總計算平均值、標準差等統計數值
- Ex 2: Kaggle 比賽要上傳的結果

測試程式碼

- 有時候原始資料太大了，有些資料的操作很費時，先在具有同樣結構的資料上測試程式碼是否能夠得到理想中的結果。
- 不確定視覺化程式碼中所需要的資料結構，用新建立的 dataframe 結構來去了解，而不是急著在原始資料上操作。

重要知識點複習

CUPOY

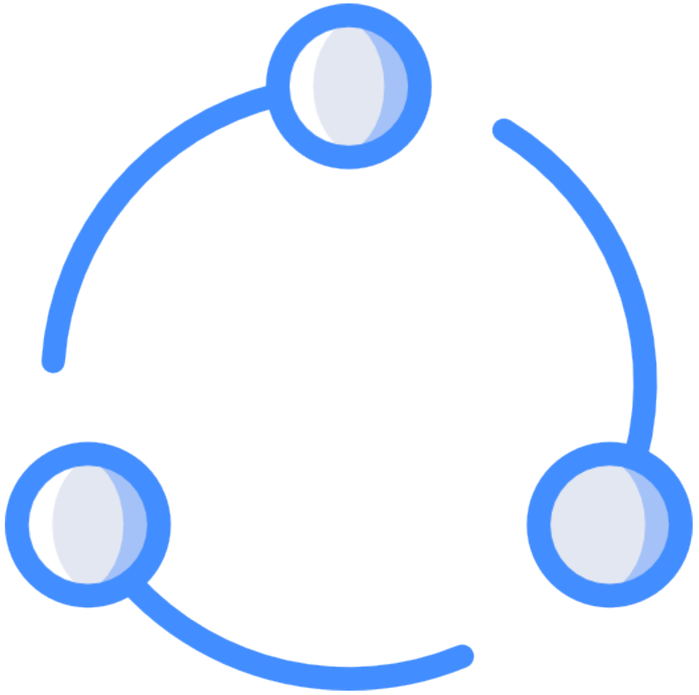

- 在資料量很大時，可以先在和資料具有同樣結構的小樣本驗證程式碼執行的結果是否符合預期
- 用 pd.DataFrame 來創建一個 dataframe
- 用 np.random.randint 來產生隨機數值

Day 5-2 資料清理數據前處理

如何讀取其他資料？(非CSV的資料)

出題教練 游為翔 / 杜靖愷

本日知識點目標

學會如何讀取其他資料格式：txt / jpg / png / json / mat / npy / pkl ...

讀取其他非csv資料格式？

CUPOY

檔案格式	讀取範例
文本 (txt)	with open(‘example.txt’, ‘r’) as f: data = f.readlines() print(data)
Json	import json with open(‘example.json’, ‘r’) as f: data = json.load(f) print(data)
矩陣檔 (mat)	iimport scipy.io as sio data = sio.loadmat(‘example.mat’)

讀取其他非csv資料格式？

CUPOY

檔案格式	讀取範例

圖像檔 (PNG / JPG …)	Import cv2
	image = cv2.imread(...) # 注意 cv2 會以 BGR 讀入
	image = cv2.cvtcolor(image, cv2.COLOR_BGR2RGB)
	
	from PIL import Image
	image = Image.read(...)
	import skimage.io as skio
	image = skio.imread(...)

Python npy	import numpy as np arr = np.load(example.npy)
Pickle (pkl)	import pickle with open(‘example.pkl’, ‘rb’) as f: arr = pickle.load(f)

重要知識點複習

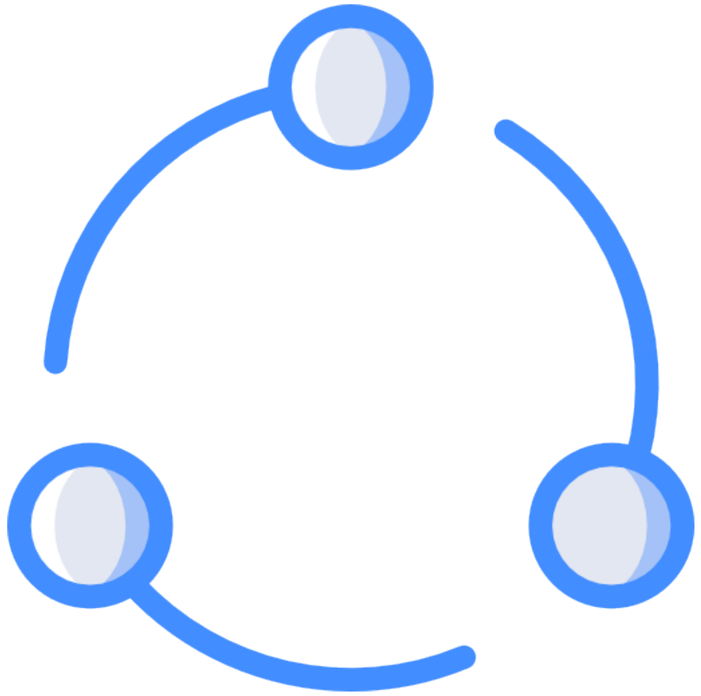

- 不同的資料有不同讀取方式
  - 文字格式通常可以用 with open()
  - 圖像格式可以使用 PIL, Skimage 或是 CV2
    - CV2 的速度較快，但須注意讀入的格式為 BGR
  - 其他形式如 npy / pickle 可以儲存經過處理後的資料

延伸閱讀

除了每日知識點的基礎之外，推薦的延伸閱讀能補足學員們對該知識點的了解程度，建議您解完每日題目後，若有多餘時間，可再補充延伸閱讀文章內容。

推薦延伸閱讀

CUPOY

Pandas Foundations

[網頁連結]

第一個 chapter 是免費的，建議可用來預習 pandas，如果覺得英文聽不懂也沒關係，可以按部就班跟著我們後面的課程，也可以學到相關的內容。

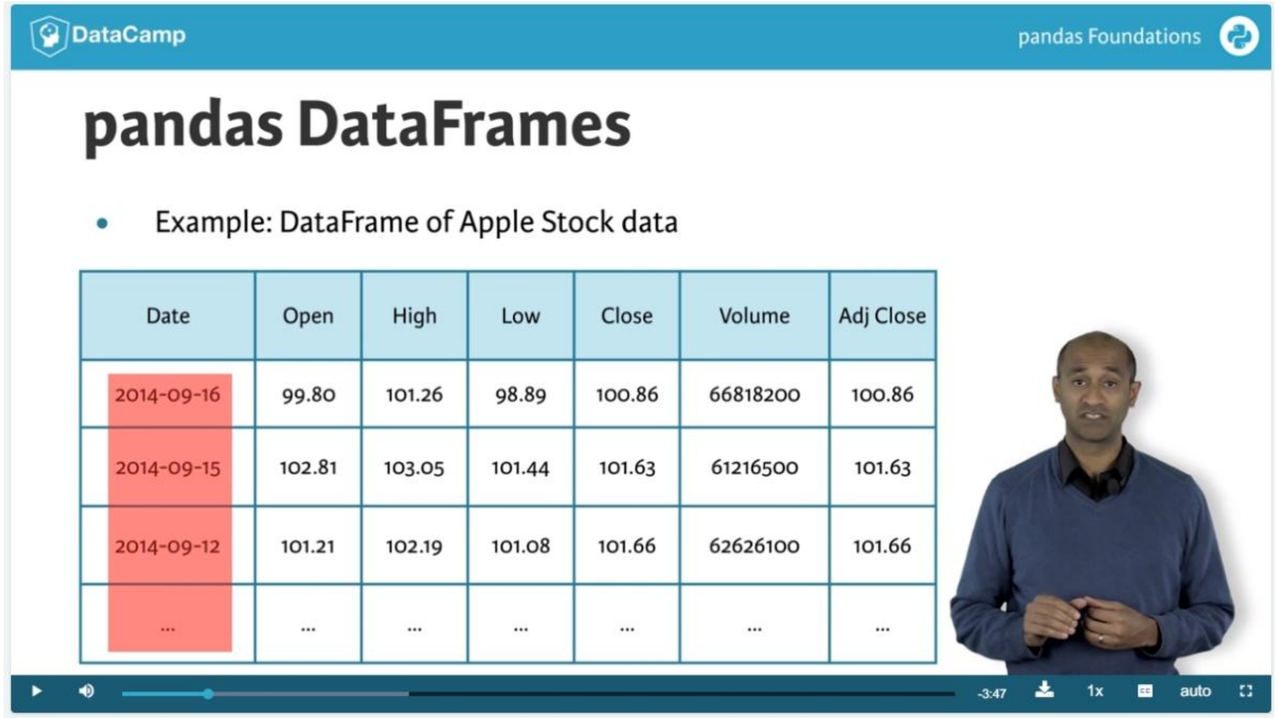

推薦延伸閱讀

CUPOY

推薦 github repo

馬拉松之後也會有 pandas 操作相關的練習，但若你迫不及待想要更精進自己 pandas 技能，可以到這個 [github repo](#) 挑戰！

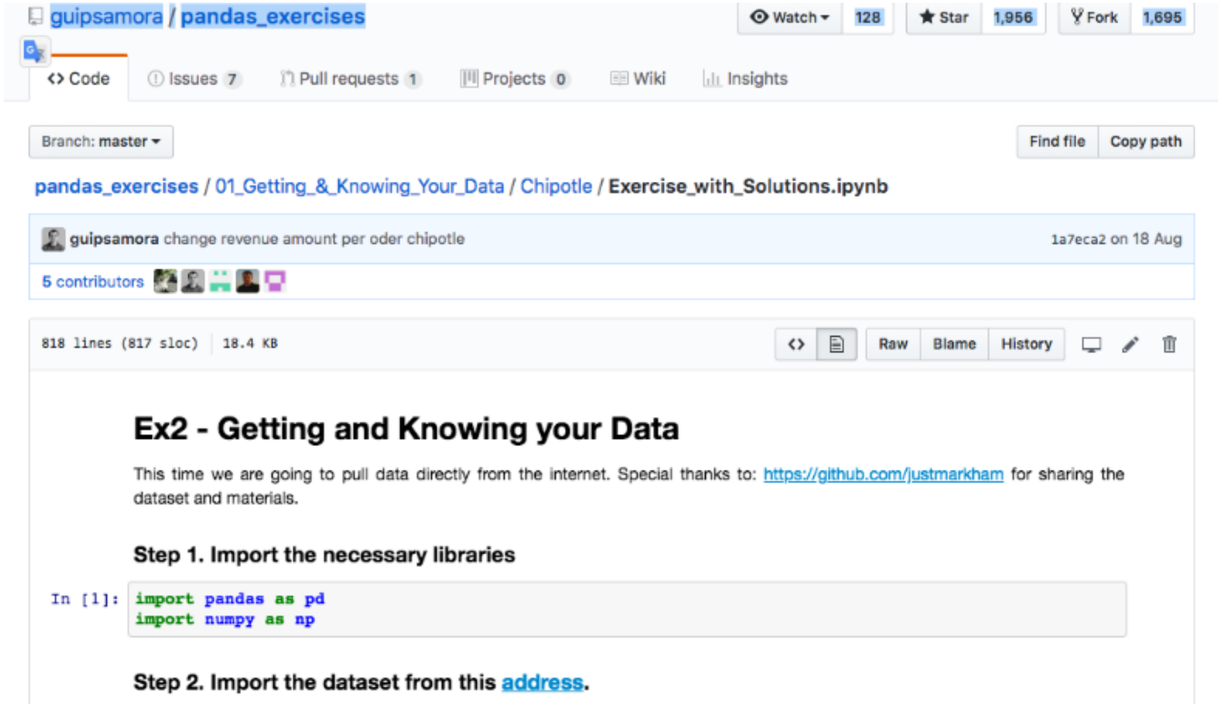

解題時間
It’s Your Turn

請跳出PDF至官網Sample Code＆作業
開始解題